

# Лабораторная работа № 1. Распознавание типов формальных языков и грамматик

## Цель:

- закрепить понятия «алфавит», «цепочка», «формальная грамматика» и «формальный язык», «выводимость цепочек», «эквивалентная грамматика»;
- сформировать умения и навыки распознавания типов формальных языков и грамматик по классификации Хомского, построения эквивалентных грамматик.

## Теоретические основы

**Определение 1.** Алфавитом  $V$  называется конечное множество символов.

**Определение 2.** Цепочкой  $\alpha$  в алфавите  $V$  называется любая конечная последовательность символов этого алфавита.

**Определение 3.** Цепочка, которая не содержит ни одного символа, называется пустой цепочкой и обозначается  $\varepsilon$ .

**Определение 4.** Формальное определение цепочки символов в алфавите:

- 1)  $\varepsilon$  - цепочка в алфавите  $V$ ;
- 2) если  $\alpha$  - цепочка в алфавите  $V$  и  $a$  - символ этого алфавита, то  $\alpha a$  - цепочка в алфавите  $V$ ;
- 3)  $\beta$  - цепочка в алфавите  $V$  тогда и только тогда, когда она является таковой в силу утверждений 1) и 2).

**Определение 5.** Длиной цепочки  $\alpha$  называется число составляющих ее символов (обозначается  $|\alpha|$ ).

Обозначим через  $V^*$  множество, содержащее все цепочки в алфавите  $V$ , включая пустую цепочку  $\varepsilon$ , а через  $V^+$  - множество, содержащее все цепочки в алфавите  $V$ , исключая пустую цепочку  $\varepsilon$ .

**Пример 1.** Пусть  $V = \{0, 1\}$ , тогда  $V^* = \{\varepsilon, 0, 1, 00, 01, 10, 11, 000, \dots\}$ , а  $V^+ = \{0, 1, 00, 01, 10, 11, 000, \dots\}$ .

**Определение 6.** Формальной грамматикой называется четверка вида:

$$G = \{T, N, P, S\}, \text{ где}$$

$N$  - конечное множество нетерминальных символов грамматики (обычно прописные латинские буквы);

$T$  - множество терминальных символов грамматики (обычно строчные латинские буквы, цифры, и т.п.),  $T \cap N = \emptyset$ ;

$P$  - множество правил вывода грамматики, являющееся конечным подмножеством множества  $(T \cup N)^+ \times (T \cup N)^*$ ; элемент  $(\alpha, \beta)$  множества  $P$  называется правилом вывода и записывается в виде  $\alpha \rightarrow \beta$  (читается: «из цепочки  $\alpha$  выводится цепочка  $\beta$ »);

$S$  - начальный символ грамматики,  $S \in N$ .

Для записи правил вывода с одинаковыми левыми частями вида  $\alpha \rightarrow \beta_1, \alpha \rightarrow \beta_2, \dots, \alpha \rightarrow \beta_n$  используется сокращенная форма записи  $\alpha \rightarrow \beta_1 \mid \beta_2 \mid \dots \mid \beta_n$ .

**Пример 2.** Грамматика  $G_1 = (\{0, 1\}, \{A, S\}, P_1, S)$ , где множество  $P_1$  состоит из правил вида: 1)  $S \rightarrow 0A1$ ; 2)  $0A \rightarrow 00A1$ ; 3)  $A \rightarrow \varepsilon$ .

**Определение 7.** Цепочка  $\beta \in (T \cup N)^*$  непосредственно выводима из цепочки  $\alpha \in (T \cup N)^+$  в грамматике  $G = \{T, N, P, S\}$  (обозначается:  $\alpha \Rightarrow \beta$ ), если  $\alpha = \xi_1 \gamma \xi_2$  и  $\beta = \xi_1 \delta \xi_2$ , где  $\xi_1, \xi_2, \delta \in (T \cup N)^*$ ,  $\gamma \in (T \cup N)^+$  и правило вывода  $\gamma \rightarrow \delta$  содержится во множестве  $P$ .

**Определение 8.** Цепочка  $\beta \in (T \cup N)^*$  выводима из цепочки  $\alpha \in (T \cup N)^+$  в грамматике  $G = \{T, N, P, S\}$ , если существует последовательность цепочек  $\gamma_0, \gamma_1, \dots, \gamma_n$  ( $n \geq 0$ ) такая, что  $\alpha \Rightarrow \gamma_0 \Rightarrow \gamma_1 \Rightarrow \dots \Rightarrow \gamma_n = \beta$ .

**Пример 3.** В грамматике  $G_1 \quad S \Rightarrow^* 000111$ , т.к. существует вывод  $S \Rightarrow 0A1 \Rightarrow 00A11 \Rightarrow 000A111 \Rightarrow 000111$ .

**Определение 9.** Языком, порожденным грамматикой  $G = \{T, N, P, S\}$  называется множество всех цепочек в алфавите  $T$ , которые выводимы из начального символа грамматики  $S$  с помощью правил множества  $P$ , т.е. множество  $L(G) = \{\alpha \in T^* \mid S \Rightarrow^* \alpha\}$ .

**Пример 4.** Для грамматики  $G_1 \quad L(G_1) = \{0^n 1^n \mid n > 0\}$ .

**Определение 10.** Цепочка  $\alpha \in (T \cup N)^*$ , для которой существует вывод  $S \Rightarrow^* \alpha$ , называется сентенциальной формой в грамматике  $G = \{T, N, P, S\}$ .

**Определение 11.** Грамматики  $G_1$  и  $G_2$  называются эквивалентными, если  $L(G_1) = L(G_2)$ .

**Пример 5.** Для грамматики  $G_1$  эквивалентной будет грамматика  $G_2 = (\{0, 1\}, \{S\}, P_2, S)$ , где множество правил вывода  $P_2$  содержит правила вида  $S \rightarrow 0S1 \mid 01$ .

### Классификация грамматик по Хомскому

**Тип 0.** Грамматика  $G = \{T, N, P, S\}$  называется грамматикой типа 0, если на ее правила вывода не наложено никаких ограничений, кроме тех, которые указаны в определении грамматики.

**Тип 1.** Грамматика  $G = \{T, N, P, S\}$  называется контекстно-зависимой грамматикой (КЗ-грамматикой), если каждое правило вывода из множества  $P$  имеет вид  $\alpha \rightarrow \beta$ , где  $\alpha \in (T \cup N)^+$ ,  $\beta \in (T \cup N)^*$  и  $|\alpha| \leq |\beta|$ .

**Тип 2.** Грамматика  $G = \{T, N, P, S\}$  называется контекстно-свободной грамматикой (КС-грамматикой), если ее правила вывода имеют вид:  $A \rightarrow \beta$ , где  $A \in N$  и  $\beta \in T^*$ .

**Тип 3.** Грамматика  $G = \{T, N, P, S\}$  называется регулярной грамматикой (Р-грамматикой) выровненной вправо, если ее правила вывода имеют вид  $A \rightarrow aB \mid a$ , где  $a \in T$ ,  $A, B \in N$ .

Грамматика  $G = \{T, N, P, S\}$  называется регулярной грамматикой (Р-грамматикой) выровненной влево, если ее правила вывода имеют вид  $A \rightarrow Ba \mid a$ , где  $a \in T$ ,  $A, B \in N$ .

$aBa \mid A \rightarrow$ , где  $N T V B A V a \square \square$ , ; .

**Определение 12.** Язык  $L(G)$  называется языком типа  $k$ , если его можно описать грамматикой типа  $k$ , где  $k$  – максимально возможный номер типа грамматики.

**Пример 6.** Примеры различных типов формальных языков и грамматик по классификации Хомского. Терминалы будем обозначать строчными символами, нетерминалы – прописными буквами, начальный символ грамматики –  $S$ .

а) Язык типа 0  $L(G) = \{a^n b^{n^2-1} \mid n \geq 1\}$  определяется грамматикой с правилами вывода:

- 1)  $S \rightarrow aaCFD$ ;
- 2)  $AD \rightarrow D$ ;
- 3)  $F \rightarrow AFB \mid AB$ ;
- 4)  $Cb \rightarrow bC$ ;
- 5)  $AB \rightarrow bBA$ ;

- 6)  $CB \rightarrow C$ ;
- 7)  $Ab \rightarrow bA$ ;
- 8)  $bCD \rightarrow \varepsilon$ .

б) Контекстно-зависимый язык  $L(G) = \{a^n b^n c^n \mid n \geq 1\}$  определяется грамматикой с правилами вывода:

- 1)  $S \rightarrow aSBC \mid abc$ ;
- 2)  $bC \rightarrow bc$ ;
- 3)  $CB \rightarrow BC$ ;
- 4)  $cC \rightarrow cc$ ;
- 5)  $BB \rightarrow bb$ .

в) Контекстно-свободный язык  $L(G) = \{(ab)^n (cb)^n \mid n > 0\}$  определяется грамматикой с правилами вывода:

- 1)  $S \rightarrow aQb \mid accb$ ;
- 2)  $Q \rightarrow cSc$ .

г) Регулярный язык  $L(G) = \{w \perp \mid w \in (a, b)^+, \text{ где нет двух рядом стоящих } a\}$  определяется грамматикой с правилами вывода:

- 1)  $S \rightarrow A\perp \mid B\perp$ ;
- 2)  $A \rightarrow a \mid Ba$ ;
- 3)  $B \rightarrow b \mid Bb \mid Ab$ .

## Постановка задачи к лабораторной работе № 1

При выполнении лабораторной работы следует реализовать следующие действия:

- 1) составить грамматику, порождающую формальный язык, заданный в соответствии с вариантом;
- 2) определить тип формальной грамматики и языка по классификации Хомского;
- 3) разработать программное обеспечение, распознающее принадлежность введенного слова составленной грамматике.

## Варианты индивидуальных заданий:

- 1)  $L(G) = \{a^n b^m c^k \mid n, m, k > 0\}$
- 2)  $L(G) = \{(ab)^n (cb)^m \mid n, m \geq 0\}$
- 3)  $L(G) = \{0^n (10)^m \mid n, m \geq 0\}$
- 4)  $L(G) = \{wcw c w \mid w \in \{a, b\}^+\}$
- 5)  $L(G) = \{c^{2n} d^n \mid n > 0\}$
- 6)  $L(G) = \{l+l-l \mid l \in \{a, b\}^+\}$
- 7)  $L(G) = \{(10)^{n-1} (01)^{n+1} \mid n > 0\}$
- 8)  $L(G) = \{(ac)^n \mid n > 0, a \in \{b, d\}, c \in \{+, -\}\}$
- 9)  $L(G) = \{100, 0100, 1100, 00100, 01100, 11100, 000100, 001100, 011100, 111100, 101100, 0000100, 0001100, 0011100, 0111100, 0101100, 1111100, 1101100, 1010100, \dots\}$
- 10)  $L(G) = \{a_1 a_2 \dots a_n a_1 a_2 \dots a_n \mid a_i \in \{0, 1\}\}$
- 11)  $L(G) = \{a_1 a_2 \dots a_n a_1 a_2 \dots a_n \mid a_i \in \{c, d\}\}$
- 12)  $L(G) = \{ab.b \mid a_i \in \{+, -\}, b \in \{0, 1, 2, 3, 4, 5, 6, 7, 8, 9\}^+\}$
- 13)  $L(G) = \{ABBB, AABBBB, AAABBBBB, \dots\}$
- 14)  $L(G) = \{AAB, AAABBB, AAAABBBB, \dots\}$
- 15)  $L(G) = \{ABBB, AABBBB, AAAABBBB, \dots\}$

- 16)  $L(G) = \{A, AAB, AAA BBB, AAAA BBBB, \dots\}$
- 17)  $L(G) = \{B, BBB, AB BBB, AAB BBBB, \dots\}$
- 18)  $L(G) = \{B, ABB, AAB BB, AAA BBBB, \dots\}$
- 19)  $L(G) = \{01010, 0110110, 011101110, \dots\}$
- 20)  $L(G) = \{ABBA B, ABA BB ABA B, ABA BA BB ABA BA B, \dots\}$
- 21)  $L(G) = \{1, 11, 01, 111, 101, 011, 1111, 1101, 0101, 0111, 11111, 11101, 10111, 10101, 01011, 011111, \dots\}$
- 22)  $L(G) = \{1, 01, 11, 001, 011, 101, 111, \dots\}$
- 23)  $L(G) = \{01, 001, 0001, 1001, 00001, 10001, 000001, 100001, 101001, \dots\}$
- 24)  $L(G) = \{\varepsilon, A, B, BA, AA, AB, BA, BB, BA, BB, BB, AAA, AAB, AAB, ABA, ABB, ABB, ABA, ABB, ABB, BAA, BAB, BAB, BBA, BBB, BBB, BBA, BBB, BBA, BBB, \dots\}$
- 25)  $L(G) = \{AB, AB, ABA B, ABA B, ABA B, ABA B, ABA BA B, ABA BA B, ABA BA B, ABA BA B, ABA BA B, ABA BA B, ABA BA B, ABA BA B, \dots\}$
- 26)  $L(G) = \{a_1 a_2 \dots a_n a_n \dots a_2 a_1 \mid a_i \in \{0, 1\}\}$
- 27)  $L(G) = \{a_1 a_2 \dots a_n a_1 a_2 \dots a_n \mid a_i \in \{c, d\}\}$
- 28)  $L(G) = \{ab.b \mid a_i \in \{+, -\}, b \in \{0, 1, 2, 3, 4, 5, 6, 7, 8, 9\}^+\}$
- 29)  $L(G) = \{a^n b^m c^k \mid n, m, k > 0\}$
- 30)  $L(G) = \{(ab)^n (cb)^m \mid n, m \geq 0\}$
- 31)  $L(G) = \{0^n (10)^m \mid n, m \geq 0\}$
- 32)  $L(G) = \{wcwcw \mid w \in \{a, b\}^+\}$